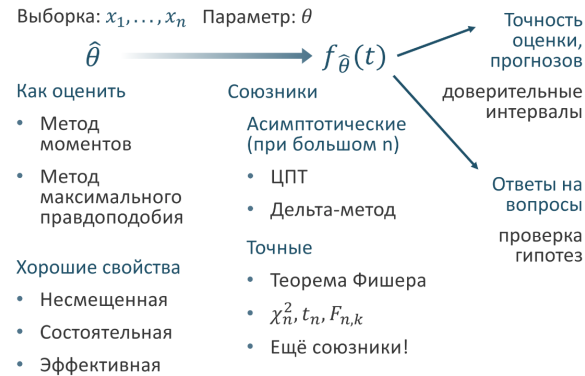


Шпаргалка по математической статистике

Схема математической статистики



Метод Моментов

Чтобы использовать метод моментов, необходимо предположить две вещи:

- $X_1, \dots, X_n \sim iid$, Independent and Identically Distributed random values
- Предположить распределение из которого пришла выборка

Момент $E(X_i^k)$ зависит от неизвестного параметра θ :
 $E(X_i^k) = f(\theta)$

Оценкой метода моментов называется случайная величина: $\hat{\theta}_{MM} = f^{-1}(X^k)$

Замечание: Нам позволяет так делать ЗБЧ, который говорит, что $\bar{X} = E(X)$

Замечание: Обычно хватает среднего первого порядка, но иногда нужно использовать более высокие порядки (например если среднее равно нулю)

Свойства оценок

Несмещенность

Оценка называется **несмещённой**, если её математическое ожидание равно оцениваемому параметру: $E(\hat{\theta}) = \theta$

Смещение оценки это разница между её математическим ожиданием и её реальным значением: $bias(\hat{\theta}) = E(\hat{\theta}) - \theta$

Состоятельность

Оценка называется **состоятельной**, если она сходится по вероятности к истинному значению параметра при $n \rightarrow \infty$:
 $\hat{\theta} \xrightarrow{P} \theta$

Асимптотическая несмещенность

Оценка называется асимптотически несмещенной, если её математическое ожидание сходится к оцениваемому параметру при $n \rightarrow \infty$, т.е: $E(\hat{\theta}) \xrightarrow{n \rightarrow \infty} \theta$

Эффективность

Обычно оценки сравнивают между собой с помощью квадратичной ошибки: $MSE = E(\hat{\theta} - \theta)^2$

Чем меньше, тем лучше

Статистик хочет получить:

- несмещенную оценку - хочет в среднем не ошибаться при фиксированном размере выборки
- состоятельную оценку - хочет при большом объеме выборки быть близко к реальности
- оценку с маленькой средней квадратичной ошибкой

Разложение на смещение и разброс

$$MSE = E(\hat{\theta} - E(\hat{\theta}))^2 + (E(\hat{\theta}) - \theta)^2 = Var(\hat{\theta}) + bias^2(\hat{\theta})$$

Низкий разброс

Высокий разброс

Низкое смещение



Высокое смещение



В классе всех возможных оценок наилучшей в смысле среднеквадратического подхода не существует, но можно зафиксировать смещение и найти оценку с наименьшей дисперсией (а.к.а. разбросом). Такая оценка называется эффективной в классе со смещением $bias(\hat{\theta})$. Для функции потерь MSE существует теоретическая нижняя граница, ее называют неравенством Рао-Фреше-Крамера.

Неравенство Рао-Фреше-Крамера

Если оценка параметра несмещена и выполнены условия регулярности:

- Область определения случайной величины не зависит от параметра θ
- Можно брать производные от функции плотности
- Существует конечная $J(\theta) = E\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2$

То верно: $Var(\hat{\theta}) \geq \frac{1}{n \cdot J(\theta)}$

Если оказалось, что $Var(\hat{\theta}) = \frac{1}{n \cdot J(\theta)}$, то $\hat{\theta}$ - эффективная оценка для θ

Замечание: Если $\hat{\theta}$ - смещенная, то в числителе вместо 1 стоит $(1 + bias'(\theta))^2$, а в остальном все аналогично

Доверительные интервалы

Интервал $[\theta_L; \theta_U]$ называется **доверительным интервалом** для параметра θ , с уровнем доверия $1 - \alpha$, если при бесконечном повторении эксперимента в $100 \cdot (1 - \alpha)$ процентах случаев этот интервал будет покрывать значение параметра θ

Величину α называют уровнем значимости

Зачем нужны доверительные интервалы?

- Точечная оценка делается по случайной выборке, а значит возникает неопределенность (т.к. выборка отличается от случая к случаю)
- Нужно делать выводы в каком-то диапазоне
- Доверительный интервал показывает, насколько мы уверены в точечной оценке

Замечание: Обычно ищут наиболее короткий интервал, т.к. уже значит точнее

Асимптотический доверительный интервал для среднего

- ЦПТ позволяет построить интервал для любого среднего т.к. для ЦПТ не важно распределение величины
- Наблюдаем X_1, \dots, X_n
- Предполагаем: X_i независимо и одинаково распределены, число n велико, **нет выбросов**

$$\bar{x} \overset{asy}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right) \underset{\text{цент.}}{\Leftrightarrow} \bar{x} - \mu \overset{asy}{\sim} N\left(0, \frac{\sigma^2}{n}\right) \underset{\text{норм.}}{\Leftrightarrow} \frac{\bar{x} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \overset{asy}{\sim} N(0, 1)$$

$$P\left(\bar{x} - z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}\right) = 1 - \alpha$$

или более просто: $\bar{x} \pm z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}$

Дельта-метод

Если:

$X_1, \dots, X_n \sim iid$, $E(X_1) = \mu$, $Var(X_1) = \sigma^2$ и $g(t)$ - дифференцируемая функция, тогда:

$$g(\bar{x}) \sim N\left(g(\mu), \frac{\sigma^2}{n} \cdot g'(\mu)^2\right),$$

тогда доверительный интервал: $g(\bar{x}) \pm z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}} g'(\mu)$

Асимптотический доверительный интервал для дисперсии

$s^2 = \frac{n}{n-1} \hat{\sigma}^2 \Rightarrow s^2 \sim N\left(\sigma^2, \frac{\mu_4 - \sigma^4}{n}\right)$, $\mu_4 = E[(X_i - \mu)^4]$ Затем можно построить доверительный интервал, более подробно об интервалах для дисперсий смотри в разделе точных интервалов

Хи-квадрат распределение

$$X_1, \dots, X_k \sim iid N(0, 1)$$

$$Y = X_1^2 + \dots + X_k^2 \sim \chi_k^2$$

Характеристики:

$$E(Y) = k, \text{Var}(Y) = 2k$$

$$\text{Плотность: } f(x) = \frac{1}{2^{\frac{k}{2}} \cdot \Gamma(\frac{k}{2})} \cdot x^{\frac{k}{2}-1} \cdot e^{-\frac{x}{2}}, x \geq 0$$

Распределение Стьюдента

$$X_0 \sim iid N(0, 1), Y \sim \chi_k^2$$

$$Z = \frac{X_0}{\sqrt{Y/k}} \sim t(k)$$

Характеристики:

$$E(Z) = 0, \text{Var}(Z) = \frac{k}{k-2}, k > 2$$

$$\text{Плотность: } f(x) = \frac{\Gamma(\frac{k+1}{2})}{\sqrt{\pi k} \cdot \frac{k}{2}} \cdot (1 + \frac{x^2}{k})^{-\frac{k+1}{2}}$$

Распределение Фишера

$$X \sim \chi_k^2, Y \sim \chi_m^2$$

$$Z = \frac{\sqrt{X/k}}{\sqrt{Y/m}} \sim F(k, m)$$

Характеристики:

$$E(Z) = \frac{m}{m-2}, m > 2, \text{Var}(Z) = \frac{2m^2(k+m-2)}{k(m-2)^2(m-4)}, m > 4$$

Плотность: *тут очень большая формула*

Теорема Фишера

Пусть $X_1, \dots, X_k \sim iid N(0, 1)$, тогда

- Выборочное среднее \bar{x} и дисперсия s^2 независимы
- $\frac{(n-1) \cdot s^2}{\sigma^2}$ имеет χ^2 - распределение с $n-1$ степенью свободы т.е. $\frac{(n-1) \cdot s^2}{\sigma^2} \sim \chi_{n-1}^2$

Точные доверительные интервалы для нормальных выборок

Обязательное условие: $X_1, \dots, X_n \sim iid N(\mu, \sigma^2)$

Точный доверительный интервал для среднего

- Дисперсия известна** σ^2 - известна и
 $\hat{\mu} = \bar{x} = \frac{X_1 + \dots + X_n}{n} \sim N(\mu, \frac{\sigma^2}{n})$
Тогда доверительный интервал:
 $P(\bar{x} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}) = 1 - \alpha$ или
проще: $\bar{x} \pm z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$
- Дисперсия не известна** σ^2 - не известна и
 $\hat{\mu} = \bar{x} \sim N(\mu, \frac{\sigma^2}{n})$
 $\frac{\bar{x} - \mu}{\sqrt{\frac{s^2}{n}}} \sim t(n-1)$
Тогда доверительный интервал:
 $P(\bar{x} - t_{1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}}) = 1 - \alpha$ или
проще: $\bar{x} \pm t_{1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$

Точный vs Асимптотический

Асимптотический

- Союзник: ЦПТ
- Работает при большом n
- Выборка независимая, без аномалий

Точный

- Союзники: теорема Фишера, t-распределение
- Работает при любом n
- Выборка независимая из нормального распределения

Точные доверительные интервалы для разности средних

Дисперсии неизвестны (асимптотика)

$$\bar{x} - \bar{y} \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}$$

Дисперсии известны (точный)

$$\bar{x} - \bar{y} \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}$$

Дисперсии неизвестны, но равны (точный)

$$\bar{x} - \bar{y} \pm t(n_x + n_y - 2)_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{s^2}{n_x} + \frac{s^2}{n_y}}$$

Дисперсии неизвестны и не равны (примерный)

$$\bar{x} - \bar{y} \pm t(v)_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}$$

где v - приближенное распределение Уэлча

Точные доверительные интервалы для дисперсии

- Мат. ожидание известно
 $P(\frac{n \cdot s^2}{\chi_{n-1}^2(1-\frac{\alpha}{2})} \leq \sigma^2 \leq \frac{n \cdot s^2}{\chi_{n-1}^2(\frac{\alpha}{2})}) = 1 - \alpha$
- Мат. ожидание НЕизвестно
 $P(\frac{(n-1) \cdot s^2}{\chi_{n-1}^2(1-\frac{\alpha}{2})} \leq \sigma^2 \leq \frac{(n-1) \cdot s^2}{\chi_{n-1}^2(\frac{\alpha}{2})}) = 1 - \alpha$

Точный доверительный интервал для отношения дисперсий независимых выборок


$$\frac{s_x^2}{s_y^2} F_{n-1, m-1}(\frac{\alpha}{2}) \leq \frac{\sigma_x^2}{\sigma_y^2} \leq \frac{s_x^2}{s_y^2} F_{n-1, m-1}(1 - \frac{\alpha}{2})$$

Проверка гипотез

Гипотеза - утверждение, которое возникло в нашей голове и которое мы собираемся проверить по данным.


Процедура проверки гипотез

- Фиксируем уровень значимости α (вероятность зря отвергнуть нулевую гипотезу)
- Формируем нулевую H_0 и альтернативную H_a гипотезы
- Выбираем союзника для проверки гипотезы
- Находим наблюдаемое значение
- Находим критическое значение с помощью союзника
- Сравниваем наблюдаемое значение с критическим и делаем выводы



p-значение

p-значение - это достигаемый уровень значимости



- если $p_value > \alpha$, то наблюдаемое значение попало в область между критическими, а значит гипотеза **не отвергается**
- если $p_value < \alpha$, то наблюдаемое значение не попало в область между критическими, а значит гипотеза **отвергается**

Вопрос: Какой уровень значимости надо брать, чтобы гипотеза впервые отверглась?

Ответ: равный p-значению

Ошибки 1-ого и 2-ого рода

	H_0 верна	H_0 неверна	ошибка 2 рода
H_0 не отвергается	ok	β	
H_0 отвергается	α	ok	
ошибка 1 рода			

$$\alpha = P(H_0 \text{ отвергнута} \mid H_0 \text{ верна})$$

$$\beta = P(H_0 \text{ не отвергнута} \mid H_0 \text{ не верна})$$

Величину $1 - \beta$ называют **мощностью** критерия

Замечание: При уменьшении ошибки первого рода всегда возрастает ошибка второго рода

Параметрические критерии

Включают в себя расчёт параметров конкретного распределения (т.е. предполагаем, что данные пришли из определенного распределения)

Критерии о долях

Z-критерий для доли

$X_1, \dots, X_N \sim iid Bern(p)$

$H_0: p = p_0$

$H_a: p \neq p_0$

ЦПТ: $\hat{p} \overset{asy}{\sim}_{H_0} N\left(p_0, \frac{p_0(1-p_0)}{n}\right)$

Критерий для проверки: $z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \overset{asy}{\sim}_{H_0} N(0, 1)$

Z-критерий для разности независимых долей

$X_1, \dots, X_N \sim iid Bern(p_x)$

$Y_1, \dots, Y_N \sim iid Bern(p_y)$

Выборки независимые

$H_0: p_x = p_y, H_a: p_x \neq p_y$

$z = \frac{p_x - p_y}{\sqrt{P(1-P) \cdot (\frac{1}{n_x} + \frac{1}{n_y})}} \overset{asy}{\sim}_{H_0} N(0, 1), P = \frac{m_x + m_y}{n_x + n_y}$, где m_i -

число 1 в выборке

Z-критерий для разности зависимых долей

$X_1, \dots, X_N \sim iid Bern(p_x)$

$Y_1, \dots, Y_N \sim iid Bern(p_y)$

Выборки независимые

$H_0: p_x = p_y, H_a: p_x \neq p_y$

		X	
		0	1
Y	0	a	b
	1	c	d

$z = \frac{c-b}{\sqrt{c+b - \frac{(c-b)^2}{n}}} \overset{asy}{\sim}_{H_0} N(0, 1)$

Критерии о средних

Z-критерий для средних

$X_1, \dots, X_N \sim iid(\mu, \sigma^2)$

$H_0: \mu = \mu_0$

$H_a: \mu \neq \mu_0$

ЦПТ: $\bar{x} \overset{asy}{\sim}_{H_0} N\left(\mu_0, \frac{\sigma^2}{n}\right)$

Критерий для проверки: $z = \frac{\bar{x} - \mu_0}{\sqrt{\frac{\sigma^2}{n}}} \overset{asy}{\sim}_{H_0} N(0, 1)$

Замечание: Данный критерий может быть использован для любых распределений, а вот следующий только для нормального

t-критерий для средних

$X_1, \dots, X_N \sim iid N(\mu, \sigma^2)$

$H_0: \mu = \mu_0$

$H_a: \mu \neq \mu_0$

σ^2 - известна

ЦПТ: $\bar{x} \sim_{H_0} N\left(\mu_0, \frac{\sigma^2}{n}\right)$

Критерий для проверки: $z = \frac{\bar{x} - \mu_0}{\sqrt{\frac{\sigma^2}{n}}} \sim_{H_0} N(0, 1)$

σ^2 - НЕ известна
ЦПТ: $\bar{x} \sim_{H_0} N\left(\mu_0, \frac{\sigma^2}{n}\right)$

Критерий для проверки: $z = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2}{n}}} \sim_{H_0} t(n-1)$

Z-критерий для разности средних

$X_1, \dots, X_N \sim iid(\mu_1, \sigma_1^2)$

$Y_1, \dots, Y_N \sim iid(\mu_2, \sigma_2^2)$

Выборки независимые

$H_0: \mu_1 = \mu_2$

$H_a: \mu_1 \neq \mu_2$

ЦПТ: $\bar{X}_1 - \bar{X}_2 \overset{asy}{\sim}_{H_0} N\left(0, \frac{s_1^2}{n} + \frac{s_2^2}{m}\right)$

Критерий для проверки: $z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}}} \overset{asy}{\sim}_{H_0} N(0, 1)$

Точные критерии для разности средних

Критерий для проверки:

дисперсии известны $z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim_{H_0} N(0, 1)$ Нормальное распределение

дисперсии неизвестны, но равны $t = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s^2}{n} + \frac{s^2}{m}}} \sim_{H_0} t(n+m-2)$ Распределение Стьюдента

дисперсии неизвестны $t = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}}} \sim_{H_0} t(v)$ Распределение Уэлча
 $v = \frac{\frac{s_1^4}{n_1^2(n_1-1)} + \frac{s_2^4}{n_2^2(n_2-1)}}{\frac{(s_1^2/n_1 + s_2^2/n_2)^2}{n_1 + n_2}}$

Критерии о дисперсиях

χ^2 - критерий для дисперсии

$X_1, \dots, X_N \sim iid N(\mu, \sigma^2)$

μ - известно

$H_0: \sigma^2 = \sigma_0^2$

$H_a: \sigma^2 > \sigma_0^2$

Критерий для проверки:

$\frac{n * s^2}{\sigma_0^2} = \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma_0^2} \sim_{H_0} \chi_{n-1}^2$

- Высокая дисперсия связана с риском и нестабильностью
- Мы хотим знать, принимает ли дисперсия своё значение ниже σ_0^2
- Из-за этого в качестве альтернативы обычно используют правостороннюю

μ - НЕ известно

$H_0: \sigma^2 = \sigma_0^2$

$H_a: \sigma^2 > \sigma_0^2$

Критерий для проверки:

$\frac{(n-1) * s^2}{\sigma_0^2} = \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma_0^2} \sim_{H_0} \chi_{n-1}^2$

Тест Фишера для отношения дисперсий

$X_1, \dots, X_n \sim iid N(\mu_x, \sigma_x^2)$

$Y_1, \dots, Y_m \sim iid N(\mu_y, \sigma_y^2)$


Выборки независимые

$H_0: \sigma_x = \sigma_y$

$H_a: \sigma_x \neq \sigma_y$

Критерий для проверки:

$\frac{s_x^2 \cdot \sigma_y^2}{s_y^2 \cdot \sigma_x^2} = \frac{s_x^2}{s_y^2} \sim_{H_0} F_{n-1, m-1}$



❗ Критерий точный, используется предположение о нормальности выборки

Непараметрические критерии

Такие критерии помогают не заикливаться на том из какого распределения пришла выборка

Критерий знаков

Идея: Превратить выборку в нули и единицы => можем использовать биномиальное распределение

Минусы: Теряем часть информации защитой в выборку

Пример: Критерий знаков(одновыборочный)

$X_1, \dots, X_n \sim iid$

$H_0: Median(X) = m_0$

$H_a: Median(X) \neq m_0$

Критерий для проверки:

$T = \sum_{i=1}^n [X_i > m_0] \sim Bin(0.5, n)$

Пример: Критерий знаков(двухвыборочный)

$X_1, \dots, X_n \sim iid Y_1, \dots, Y_n \sim iid$

Выборки связанные

$H_0: P(X > Y) = 0.5$

$H_a: P(X > Y) \neq 0.5$

Критерий для проверки:

$T = \sum_{i=1}^n [X_i > Y_i] \sim Bin(0.5, n)$

Ранговые критерии

x_1, x_2, \dots, x_n - выборка

$x_{(1)} \leq x_{(3)} \leq \dots \leq x_{(n)}$ - упорядочим по возрастанию

Правила выставления ранга:

1. Порядковый номер наблюдения - ранг
2. Если встречаются несколько одинаковых значений, им присваивается одинаковое значение ранга, равное среднему арифметическому их порядковых номеров

Критерий Уилкоксона (одновыборочный)

$X_1, \dots, X_n \sim iid$

$F_X(x)$ - симметрична относительно медианы

$H_0: Median(X) = m_0$

$H_a: Median(X) \neq m_0$

Критерий для проверки:

$W = \sum_{i=1}^n rank(|X_i - m_0|) * sign(X_i - m_0)$ - табличное распределение

Критерий Уилкоксона (двухвыборочный)

Предполагаем, что распределения одинаковые, хотим проверить сдвинутые ли они $X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

Выборки связанные

$H_0: Median(X - Y) = 0$

$H_a: Median(X - Y) \neq 0$

Критерий для проверки:

$W = \sum_{i=1}^n rank(|X_i - Y_i|) * sign(X_i - Y_i)$ - табличное распределение

Критерий Манна-Уитни (двухвыборочный)

$X_1, \dots, X_{n_x} \sim iid$

$Y_1, \dots, Y_{n_y} \sim iid$

Выборки независимые

$n_x \leq n_y$

$H_0: f_X(x) = f_Y(y)$

$H_a: f_X(x) = f_Y(y + m), m \neq 0$

Объединим обе выборки в одну общую и посчитаем для всех чисел ранги

Критерий для проверки:

$W = \sum_{i=1}^{n_x} rank(X_i)$ - табличное распределение

Бутстрап

Идея метода: имеющаяся выборка - это единственная информация об истинном распределении данных

Доверительный интервал Эфрона

Бутстрапируем: оценку неизвестного параметра
Сэмплируем: x_1^*, \dots, x_n^*
Считаем: $\hat{\theta}^*$
Повторяем: B раз
Строим распределение: $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$
Интервал: $[\hat{\theta}_{\alpha}^*; \hat{\theta}_{1-\alpha}^*]$

❗ Если распределение выборки несимметрично, такой доверительный интервал усиливает смещение, присущее изначальной выборке

Доверительный интервал Холла

Бутстрапируем: Отклонение оценки от истинного значения
Сэмплируем: x_1^*, \dots, x_n^*
Считаем: $\hat{q}_i^* = \hat{\theta}^* - \hat{\theta}$
Повторяем: B раз
Строим распределение: $\hat{q}_1^*, \dots, \hat{q}_B^*$
Интервал: $[\hat{\theta} - \hat{q}_{1-\frac{\alpha}{2}}^*; \hat{\theta} - \hat{q}_{\frac{\alpha}{2}}^*]$


t-процентильный доверительный интервал

Бутстрапируем: t - статистику
Сэмплируем: x_1^*, \dots, x_n^*
Считаем: $t_i^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$
Повторяем: B раз
Строим распределение: t_1^*, \dots, t_B^*
Интервал: $[\hat{\theta} - t_{1-\frac{\alpha}{2}}^* \cdot se(\hat{\theta}); \hat{\theta} - t_{\frac{\alpha}{2}}^* \cdot se(\hat{\theta})]$

❗ Если бутстрапировать $|\hat{\theta}^* - \hat{\theta}|$, можно получить симметричный интервал

Проблемы бутстрапа

- Чтобы бутстрап работал, выборка должна быть репрезентативной



- Если исходная выборка маленькая, бутстраповский доверительный интервал будет уже аналитического, так как в выборке недостаточно “неопределенности”
- Если в данных есть структура (регрессия, временные ряды), бутстрап нужно устроить так, чтобы учитывать её \Rightarrow разные виды бутстрапа
- Бутстрап ненадёжно работает в хвостах распределения из-за маленького числа наблюдений: мы можем хорошо оценить медиану, но не 99% квантиль
- Если у распределения тяжёлые хвосты, бутстрап может работать некорректно и в среднем

Проверка гипотез при помощи бутстрапа

$H_0: \theta = \theta_0$

$H_a: \theta > \theta_0$

t-статистика:

$$t = \frac{(\hat{\theta} - \theta_0)}{se(\hat{\theta})}$$

Бутстрап-аналог:

$$t^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$$

- Гипотеза отвергается, если $t_{obs} > t_{1-\alpha}^*$
- По аналогии можно проверять гипотезы против других альтернатив
- Для более сложных гипотез есть специальные бутстраповские алгоритмы проверки

Критерии согласия

Эмпирическая функция распределения

Функция распределения – функция, которая определяет вероятность события $X \leq x$, то есть $F(x) = P(X \leq x)$

Эмпирическая функция распределения – функция, которая определяет для каждого x частоту события $X \leq x$, то есть $\hat{F}_n(x) = \hat{P}(X \leq x) = \frac{1}{n} \sum_{i=1}^n [X_i \leq x]$, $[\cdot]$ – индикатор

Свойства эмпирической функции распределения

- Несмещённость: $\mathbb{E}(\hat{F}_n(x)) = F_X(x)$
- Состоятельность: $\lim_{n \rightarrow \infty} \hat{F}_n(x) = F_X(x)$
- Асимптотическая нормальность:

$$\hat{F}_n(x) \stackrel{\text{asy}}{\sim} N\left(F_X(x), \frac{\hat{F}_n(x) \cdot (1 - \hat{F}_n(x))}{n}\right)$$

Критерий Колмогорова

Используется для проверки гипотез о непрерывных распределениях

- Критерии согласия - критерий о виде неизвестного закона распределения: $H_0 : X \sim F_X(x)$, H_a : гипотеза H_0 неверна
- Распределение случайной величины описывается её функцией распределения: $H_0 : F_X(x) = F_0(x)$, $H_a : F_X(x) \neq F_0(x)$

Статистика Колмогорова:

$$D_n(X_1, \dots, X_n) = \sup_x |F_0(x) - \hat{F}_n(x)|$$

При справедливости нулевой гипотезы, распределение статистики D_n одинаково для любых **непрерывных** распределений, при этом его функция распределения:

$$\lim_{n \rightarrow \infty} \mathbb{P}(\sqrt{n} \cdot D_n \leq z) = 1 + 2 \sum_{k=1}^{\infty} (-1)^k e^{-2k^2 z^2}$$

- !** Распределение Колмогорова – наш новый союзник, на её основе мы можем построить критерий

$$X_1, \dots, X_n \sim iid F_X(x)$$

$$H_0: F_X(x) = F_0(x)$$

$$H_a: F_X(x) \neq F_0(x)$$

$$\boxed{\times} K_{\text{набл.}} > K_{1-\alpha}$$

$$\boxed{\checkmark} K_{\text{набл.}} \leq K_{1-\alpha}$$

- Критические значения рассчитываются по таблицам, составленным для распределения Колмогорова

Замечание: Для проверки гипотезы об однородности двух выборок, можно также пользоваться этой идеей, просто считать расстояние между двумя эмпирическими функциями

Замечание:

- Чтобы проверять гипотезы о распределениях, нужно научиться считать между ними расстояния
- Критерий Колмогорова ищет расстояние как супремум и позволяет проверять гипотезы о распределении и однородности выборок
- Критерии Крамера-Мизеса и Андерсона-Дарлингса помогают специфицировать критерий либо для "средиземья" либо для "крайнеземья" (хвостов)
- Эти критерии работают только для непрерывных распределений
- Неизвестные параметры распределения фиксируются в нулевой гипотезе
- Если мы оцениваем параметры по выборке, распределения Колмогорова не будет одинаковым для всех распределений
- Для различных распределений можно строить уточнения теста Колмогорова

Критерий Пирсона

Используется для проверки гипотез о дискретных распределениях

- Выборка X_1, \dots, X_n из дискретного распределения
- Предполагаем, что случайная величина принимает s значений с какими-то вероятностями

X	z_1	z_2	...	z_s	- возможные значения
$\mathbb{P}(X = z)$	$p_1(\theta)$	$p_2(\theta)$...	$p_s(\theta)$	- теоретические вероятности
$\#(X_i = z)$	v_1	v_2	...	v_s	- эмпирические частоты

- Нужно сравнить все эмпирические частоты с теоретическими $\hat{\theta}$ - состоятельная оценка параметров распределения, k - их количество

Критерий для проверки:

$$K_n = \sqrt{n} \cdot \sup_x |F_0(x) - \hat{F}_n(x)|$$

$$K_n \stackrel{\text{asy}}{\sim}_{H_0} \text{распределение Колмогорова}$$


- !** Критерий применяется только для непрерывных распределений

$$X_1, \dots, X_n \sim iid F_X(x)$$

$$H_0 : F_X(x) = F_0(x)$$

$$H_a : F_X(x) \neq F_0(x)$$

$$\text{Критерий для проверки: } \sum_{i=1}^s \frac{(v_i - n \cdot p_i(\hat{\theta}))^2}{n \cdot p_i(\hat{\theta})} \stackrel{\text{asy}}{\sim}_{H_0} \chi_{s-k-1}^2$$



- !** Критерий обычно применяют для дискретных распределений

Замечание:

- Критерий Пирсона не состоятелен против всех альтернатив, т.е. бывают распределения, которые он не может отличить друг от друга
- Можно попробовать использовать критерий Пирсона для непрерывных распределений
- Для этого нужно будет разбить все возможные значения непрерывной случайной величины на bins (как на гистограмме)
- Результат работы теста будет зависеть от числа выбранных бинов \Rightarrow лучше пользоваться для непрерывных распределений другими критериями

Гипотезы об однородности выборок


Критерий Пирсона по аналогии с критерием Колмогорова можно использовать для проверки гипотез об однородности выборок

$$X_1, \dots, X_{n_x} \sim iid F_X(x) \quad Y_1, \dots, Y_{n_y} \sim iid F_Y(y)$$

$$H_0 : F_X(x) = F_Y(y)$$

$$H_a : F_X(x) \neq F_Y(y)$$

- Нужно сравнивать эмпирические частоты между собой

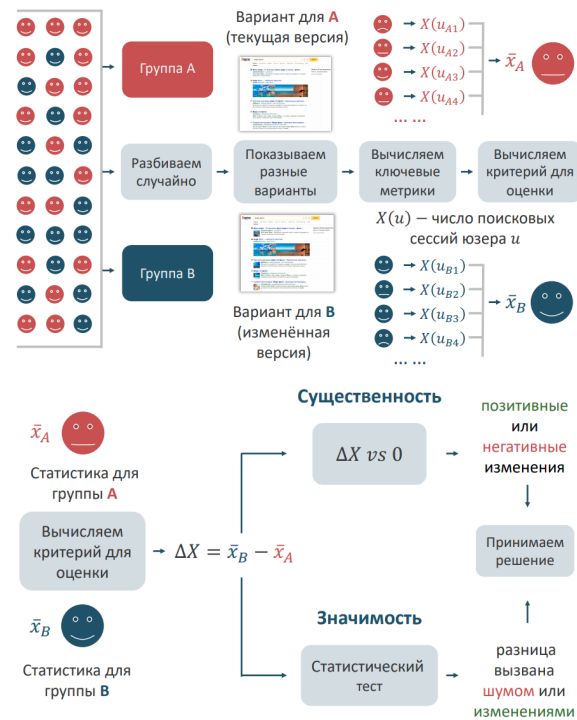


- Можно использовать критерий для непрерывных распределений, но тогда придется дробить данные на bins

Замечание:

- Его можно использовать и для непрерывных величин, но результат будет зависеть от числа выбранных групп

А/В тесты



Типичные метрики:

- Уникальные пользователи за сессию
- Клики на пользователя, клики на один запрос
- Среднее время пользователя на сайте
- Возвращаемость пользователя
- Средний чек
- Средний трафик
- Средняя разница между ценой товара и его себестоимостью (маржа)

Значимость – статистический тест говорит нам, что изменения в метрике неслучайны.

Существенность – насколько изменения большие по своей величине, насколько большой размер эффекта (изменение метрики), который мы ловим.

Замечание:

АБ-тест используется для проверки идей на группе пользователей. При проведении АБ-теста мы должны ответить на ряд вопросов:

1. Что является целевой метрикой?
2. На какое увеличение мы рассчитываем?
3. Какой критерий мы используем для проверки результата на статистическую значимость?

4. Как должен выглядеть дизайн эксперимента, как разбить пользователей на группы?

5. Как долго должен идти эксперимент?

Множественная проверка гипотез

Проблема: Проверяем две гипотезы:

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

В таком случае можем ошибиться сразу в двух местах (т.е. в одной или в другой):

$P(\text{ошибочно отвергнуть хотя бы одну из } H_0) = 1 - P(\text{не ошибиться ни в одной}) = 1 - (1 - \alpha)^2 = 2\alpha - \alpha^2 > \alpha$

Т.е. получается наша ошибка первого рода растет, а в случае n гипотез будет рост $1 - (1 - \alpha)^n$

Как можем скорректировать?

Неравенство Бонферрони

$P(A + B) \leq P(A) + P(B)$ - т.е. можем просто тестировать каждую гипотезу на уровне $\frac{\alpha}{n}$ чтобы в худшем случае получить общий уровень значимости α

Минусы?

- Из-за коррекции уровня значимости возникают проблемы с мощностью тестов
- Чем больше гипотез проверяется, тем ниже шансы отклонить неверные гипотезы
- Более того, из-за презумпции нулевой гипотезы для более низкого уровня значимости нам нужно собрать большее число наблюдений, чтобы зафиксировать значимое отклонение от нулевой гипотезы

Вывод: Нужно улучшать метод коррекции

Рассмотрим случай, когда мы проверяем n гипотез

	верных H_{0i}	неверных H_{0i}
не отвергнутых H_{0i}	U	T
отвергнутых H_{0i}	V	S

- Неверно отклонили V гипотез, неверно не отклонили T гипотез
- На практике пытаются контролировать обобщения ошибки первого рода, например: FWER и FDR

Групповая вероятность ошибки, FWER

(Family-Wise Error Rate) – это вероятность совершить хотя бы одну ошибку первого рода $FWER = P(V > 0)$

Ожидаемая доля ложных отклонений, FDR (False Discovery Rate) – это математическое ожидание числа ошибок первого рода к общему числу отклонений нулевой гипотезы $FDR = E(\frac{V}{V+S})$

Т.е. FWER пытается контролировать ошибку первого рода, когда отрицаем верную гипотезу, а FDR пытается контролировать обобщение ошибки второго рода

Метод Холма

- Поправка Бонферрони пытается контролировать FWER (вероятность хотя бы одной ошибки 1 рода)
- Метод Холма – улучшение поправки Бонферрони, обладает более высокой мощностью
- Отсортируем гипотезы по получившимся P-значениям по возрастанию: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(k)}$
- Возьмём для них: $\alpha_{(1)} = \frac{\alpha}{k}, \alpha_{(2)} = \frac{\alpha}{k-1}, \dots, \alpha_{(i)} = \frac{\alpha}{k-i+1}, \dots, \alpha_{(k)} = \alpha$
- Если $p_{(1)} \geq \alpha_{(1)}$, все нулевые гипотезы не отвергаются, иначе отвергаем первую и продолжаем
- Если $p_{(2)} \geq \alpha_{(2)}$, все оставшиеся нулевые гипотезы не отвергаются, иначе отвергаем вторую и продолжаем
- Идём, пока не кончатся гипотезы
- Метод Холма обеспечивает контроль FWER на уровне α
- Метод Холма оказывается мощнее коррективы Бонферрони, так как его уровни значимости меньше

Метод Бенджамини-Хохберга

- Отсортируем гипотезы по получившимся P-значениям по возрастанию: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(k)}$
- Возьмём для них: $\alpha_{(1)} = \frac{\alpha}{k}, \alpha_{(2)} = \frac{2\alpha}{k}, \dots, \alpha_{(i)} = \frac{i\alpha}{k}, \dots, \alpha_{(k)} = \alpha$
- Если $p_{(k)} \leq \alpha_{(k)}$, отвергнуть все гипотезы, иначе не отвергнуть k -ую и продолжить
- Если $p_{(k-1)} \leq \alpha_{(k-1)}$, отвергнуть все гипотезы, иначе не отвергнуть $(k-1)$ -ую и продолжить
- Идём, пока не кончатся гипотезы
- Для любой процедуры множественного тестирования гипотез $FDR \leq FWER$
- Метод Бенджамини-Хохберга обычно оказывается более мощным, чем методы контролируемые FWER
- Он отвергает не меньше гипотез с теми же α_i
- Это происходит за счёт того, что метод позволяет допустить большее число ошибок первого рода

А сколько наблюдений нужно?

- Необходимое количество наблюдений зависит от размеров ошибок первого и второго рода, а также от размера эффекта
- Фиксируем уровень значимости (ошибку 1 рода), на которую мы согласны
- Подбираем соотношение между минимальным размером эффекта, желаемой мощностью и объёмом выборки
- В выборе соотношении помогает заказчик эксперимента, у него обычно есть ограничения, с которыми нам придётся работать (количество магазинов, длительность АБ-теста и т.п.)

Таблица эффекта-ошибки

		Ошибка 1/2 рода $\alpha = \beta$			
		0.1%	1%	5%	10%
размер эффекта	1%	много данных			
	1.5%				
	3%				
	5%				
	10%				мало данных

- ❗ Совокупность этих трёх параметров (ошибка 1/2 рода, размер эффекта) позволяют рассчитать необходимый для эксперимента объём выборки.

Анализ мощности

До эксперимента:

- Какой нужен объём выборки, чтобы найти различия с разумной степенью уверенности
- Различия какой величины мы можем найти, если известен объём выборки

После эксперимента:

- смогли бы мы найти различия с помощью нашего эксперимента, если бы величина эффекта была равна Δ

Метрики для А/В тестирования

- Показатель для улучшения – метрика
- Метрики бывают разными, они конструируются в зависимости от бизнес-задачи
- Иногда метрики привязаны к деньгам

- Чаще всего денежные метрики грубые (слабо реагируют на изменения либо, надо очень много времени, чтобы их измерить)
- Из-за этого чистым денежным метрикам предпочтительнее промежуточные метрики

Роли метрик

- **Ключевые метрики** – отражают ключевые цели сервиса, должны обладать безусловной направленностью (если метрика растёт, сервису всегда становится лучше/хуже)
- **Основные критерии оценки изменений** – должны быть согласованы с ключевыми метриками, должны быть чувствительными
- **Ограничительные метрики** – должны быть чувствительны и согласованы с тем, что нельзя ломать
- **Целевые метрики эксперимента** – должны выбираться в зависимости от смысла эксперимента

Желательные свойства метрик

- **Согласованность** – метрика должна быть согласована с целями сервиса и его ключевыми метриками
- **Направленность** – если значение метрики изменилась, должна быть чёткая интерпретация этого изменения (хорошо это или плохо)
- **Чувствительность (sensitivity)** – способность метрики отражать статистически значимую разницу между контрольной и тестовой группами, когда она есть. Чем выше чувствительность, тем меньше данных нужно, чтобы обнаружить статистически-значимые изменения.
Пример: метрики, основанные на деньгах слабо реагируют на изменения

- **Стабильность** – метрика должна быть чувствительной и согласованной с тем, что нельзя ломать. Если у метрики высокая дисперсия, то для того, чтобы уловить значимый эффект, надо собирать много данных

Пример: розничный торговый оборот магазина может колебаться в очень широких диапазонах. Чтобы уменьшить его дисперсию, обычно смотрят торговый оборот отдельных отделов.

-

Примеры:

Лояльность пользователя:

- Число пользовательских сессий
- Время, которое юзер проводит в сервисе

Имеют чёткую направленность

Хорошие предикторы для долгосрочного успеха продукта

Обладают слабой чувствительностью

Активность пользователя:

- Число кликов за сессию
- Длина пользовательской сессии

Обладают сильной чувствительностью

Обладают неоднозначной направленностью

Пример: клики пользователей в рекомендательной системе отражают как позитивные, так и негативные сигналы

- С одной стороны, они говорят, что пользователю нравится пользоваться продуктом
- С другой, они говорят, что у нас много кликбейтного контента
- Метрики с чёткой интерпретацией часто обладают низкой чувствительностью